Analyse statistique et prédiction du rendement du maïs

Ndeye Aminata Gadiaga — Master Data Science – UPEC

Résumé

L'objectif était de comprendre quels facteurs influencent le rendement du maïs (type de sol, engrais, précipitations, température, surface) et de le prédire. L'analyse montre qu'**aucune des variables disponibles n'a d'effet mesurable sur le rendement** : les corrélations sont toutes inférieures à 0,07 en valeur absolue, l'ANOVA ne montre pas d'effet du type de sol ($p = 0{,}26$), et aucun des quatre modèles testés ne prédit mieux que la moyenne ($R^2 \leq 0$). La conclusion utile pour l'exploitation est donc qu'il faut **collecter d'autres données** avant de pouvoir optimiser ses pratiques.

1. Problème et données

Question métier : comment le type de sol, l'engrais, les précipitations, la température et la surface influencent-ils le rendement du maïs, et comment l'exploitation peut-elle s'en servir pour améliorer ses pratiques ?

Le jeu de données contient **1 000 parcelles** et 6 variables :

- **Variable cible** : rendement (t/ha).
- **Variables explicatives** : surface (ha), type de sol (argileux, limoneux, sableux), engrais (kg/ha), précipitations (mm), température (°C).

Le fichier ne contient aucune valeur manquante.

2. Statistiques descriptives du rendement

Moyenne	7,38 t/ha	Écart-type	2,57 t/ha
Médiane	7,35 t/ha	Variance	6,60
Minimum	3,00 t/ha	Maximum	12,00 t/ha
Étendue	9,00 t/ha	Valeurs aberrantes (IQR)	0

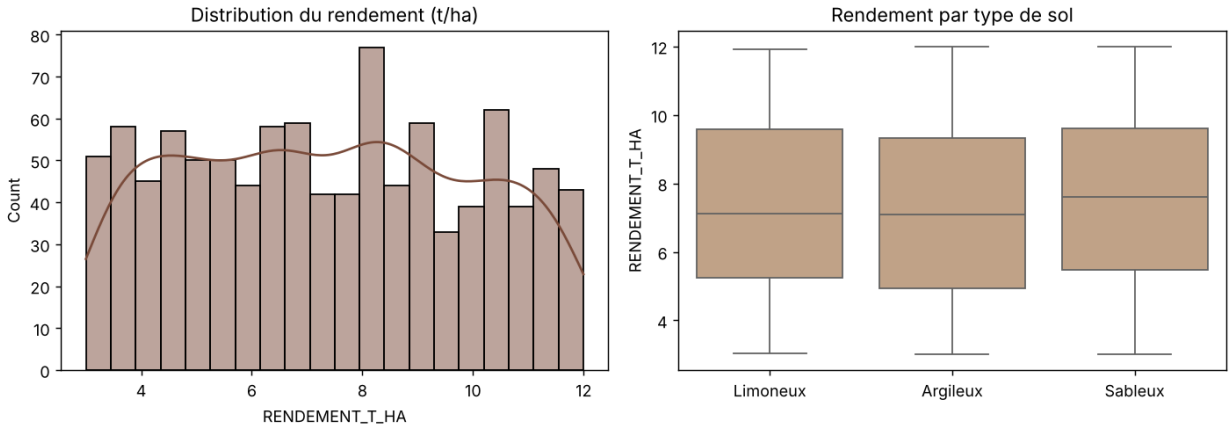


Figure 1: Distribution du rendement et rendement par type de sol

Interprétation

- La moyenne et la médiane sont presque égales : la distribution est symétrique.
- La distribution est **plate**, répartie de façon presque égale entre 3 et 12 t/ha, et non concentrée autour de la moyenne. Elle ressemble à une loi uniforme, ce qui suggère des données simulées.
- Le rendement étant une variable continue, chaque valeur n'apparaît qu'une fois : le **mode n'a pas de sens** ici et n'est pas retenu.
- La méthode de l'écart interquartile (IQR) ne détecte **aucune valeur aberrante**.

3. Corrélations

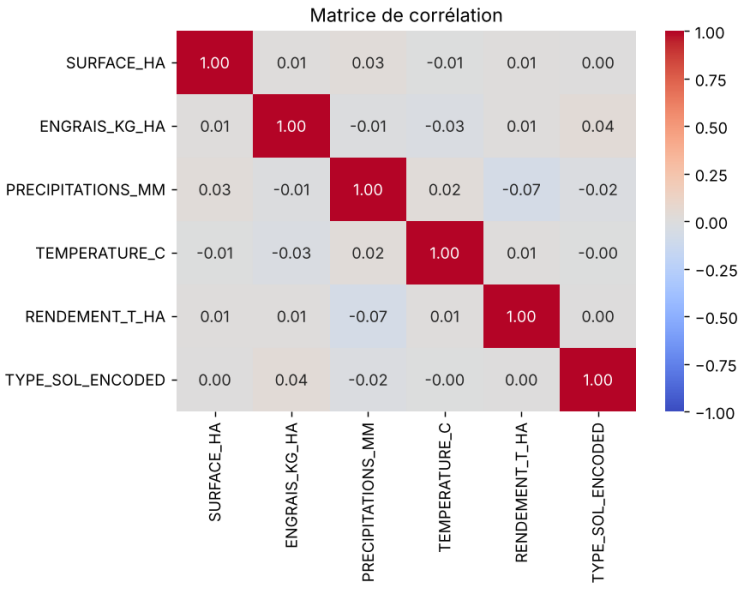


Figure 2: Matrice de corrélation des variables numériques

Toutes les corrélations avec le rendement sont **proches de 0** : précipitations ($-0{,}07$), engrais ($0{,}01$), température ($0{,}01$), surface ($0{,}01$), type de sol ($0{,}00$). Les variables explicatives ne sont pas non plus corrélées entre elles. Il n'existe donc **aucune relation linéaire** entre ces facteurs et le rendement.

4. Effet du type de sol : ANOVA

- H_0 : le rendement moyen est le même pour les trois types de sol.
- H_1 : au moins un type de sol a un rendement moyen différent.

Type de sol	Parcelles	Rendement moyen	Écart-type
Argileux	343	7,28 t/ha	2,61
Limoneux	319	7,29 t/ha	2,51
Sableux	338	7,57 t/ha	2,58

Le test donne $F = 1{,}36$ et une **p-value de 0,26**, supérieure au seuil de 0,05. On **ne rejette pas** H_0 : les écarts entre types de sol (moins de 0,3 t/ha) ne sont pas significatifs et peuvent s'expliquer par le hasard.

5. Modélisation

Quatre modèles de régression ont été entraînés sur 80 % des parcelles et évalués sur les 20 % restantes. Ils sont comparés à une **référence naïve**, qui prédit toujours le rendement moyen.

Modèle	MAE	RMSE	R^2
Référence (moyenne)	2,07	2,43	0,00
Régression linéaire	2,07	2,43	$-0{,}003$
Forêt aléatoire	2,06	2,50	$-0{,}06$
LightGBM	2,14	2,56	$-0{,}11$
XGBoost	2,21	2,68	$-0{,}22$

Interprétation

- **Aucun modèle ne fait mieux que la référence.** Un R^2 proche de 0 ou négatif signifie que le modèle n'explique rien de plus que la moyenne.
- Les modèles les plus complexes (XGBoost, LightGBM) sont les **moins bons** : ils apprennent du bruit dans les données d'entraînement (sur-apprentissage).
- Ce résultat est cohérent avec les corrélations nulles et l'ANOVA : il n'y a pas de signal à apprendre.

6. Conclusions et recommandations

Conclusion : avec les données actuelles, ni le type de sol, ni l'engrais, ni les précipitations, ni la température, ni la surface ne permettent d'expliquer ou de prédire le rendement. Les recommandations agronomiques ne peuvent donc pas s'appuyer sur ces données.

Recommandations pour l'exploitation

- **Vérifier la qualité et la provenance des données** : leur distribution uniforme et l'absence totale de corrélation suggèrent des données simulées ou mal enregistrées.
- **Collecter des variables plus explicatives** : humidité du sol, variété de maïs, dates de semis, irrigation, maladies, historique de chaque parcelle.
- **Mesurer les variables au bon moment** : des moyennes mensuelles de climat masquent les épisodes décisifs (sécheresse pendant la floraison, par exemple).

Limites et améliorations méthodologiques

- Le type de sol a été codé de 1 à 3, ce qui impose un ordre artificiel aux catégories. Un **encodage one-hot** serait plus adapté.
- Un seul découpage entraînement / test a été utilisé. Une **validation croisée** donnerait des résultats plus stables.
- Les hyperparamètres des modèles n'ont pas été optimisés. Cela ne changerait toutefois pas la conclusion, faute de signal dans les données.